UNIVERSIDADE PRESBITERIANA MACKENZIE

TECNÓLOGO EM BANCO DE DADOS

Ryan Rodrigues Pereira – 10742607 – 10742607@mackenzista.com.br

Nour Hussein Barakat – 10738273 – 10738273@mackenzista.com.br

Guilherme de Araújo Esp. Santo – 10746294 –10746294@mackenzista.com.br

ANÁLISE PREDITIVA DE PREÇOS DE LAPTOPS COM PROCESSAMENTO DE TEXTO

SÃO PAULO

2026

Contents

1. Contexto 3
1.1 Obvetivos e Metas 3
1.2 Problema de pesquisa 4
2. Cronograma 4
2.1 funções 5
3. Dataset 5
3.1 Aquisição 5
3.2 Descrição origem 6
3.3 Descrição dataset 6
4. Proposta analítica 7
4.1 Github Repository 8
4. Metodologia Analítica 8
8. Glossário 10
7. Referências 11

1. Contexto

O mercado de laptops é altamente competitivo e dinâmico, com constantes inovações tecnológicas e uma ampla diversidade de configurações disponíveis para atender diferentes perfis de consumidores. Nesse cenário, entender os fatores que determinam o preço de um laptop é fundamental tanto para fabricantes posicionarem seus produtos adequadamente quanto para consumidores realizarem escolhas mais conscientes e alinhadas às suas necessidades e orçamento.

As especificações técnicas — como processador, memória RAM, tipo de armazenamento e placa de vídeo — exercem um papel central na formação do preço, pois refletem diretamente o desempenho e a capacidade do equipamento. No entanto, outros elementos como marca, sistema operacional, tamanho da tela e resolução também podem influenciar significativamente o valor final de um laptop.

Este projeto utiliza um dataset público contendo informações detalhadas sobre diferentes modelos de laptops, incluindo suas configurações técnicas e respectivos preços em euros. A partir dessa base, buscaremos explorar quantitativamente como cada característica impacta o preço dos laptops e quais padrões podem ser identificados para auxiliar na precificação, recomendação de produtos e análise de mercado.

1.1 Objetivos e Metas

O objetivo deste projeto é analisar preços e especificações de laptops modernos utilizando técnicas de ciência de dados e aprendizado de máquina, buscando entender quais características mais influenciam o preço e construir um modelo preditivo.

Como metas, o grupo pretende: limpar e preparar os dados do dataset; realizar análise exploratória dos dados; aplicar técnicas estatísticas; treinar modelos de regressão para prever o preço; e apresentar os resultados de forma clara com visualizações e storytelling.

Pergunta central:

Quais características técnicas mais influenciam o preço de laptops e qual modelo de regressão apresenta melhor desempenho na predição desse valor?

1.2 Problema de pesquisa

O mercado de laptops apresenta grande variação de preços, mesmo entre modelos com especificações semelhantes, o que dificulta a compreensão dos fatores que realmente impactam o valor final do produto.

Dessa forma, este projeto busca identificar quais características técnicas mais influenciam o preço dos laptops e avaliar a capacidade de modelos de regressão em prever esse valor com base nessas variáveis.

2. Cronograma

Mês	Fase	Resultados
Março 2026	Kick-off: definição do grupo, dataset e cronograma	Entrega Etapa 1
Abril 2026	EDA, limpeza dos dados	Entrega Etapa 2
Maio 2026	APRESENTAÇÃO DE PRODUTOS E STORYTELLING	Entrega Etapa 3
Junho 2026	Relatório final, Data Storytelling e apresentação	Entrega Etapa 4 — nota final

2.1 funções

Integrante (Ra)	Papel No Projeto	Responsabilidades	Entregáveis
Nour Hussein Barakat (10738273)	Análise & Modelagem	Análise exploratória, visualizações, métricas de atraso, segmentações e modelagem preditiva.	Notebooks de análise, gráficos e dashboard final.
Guilherme De Araújo Esp. Santo (10746294)	Coordenação & Documentação	Organização do escopo, padronização do documento e referências, gestão do GitHub, apoio ao vídeo final.	Relatório final, README estruturado, vídeo síntese.
Ryan Rodrigues Pereira (10742607)	Engenharia de Dados (ETL)	Ingestão, limpeza e integração das tabelas. Criação do DataFrame master.	Notebook ETL, dicionário de metadados.

3. Dataset

Este capítulo descreve a origem, aquisição e estrutura do conjunto de dados utilizado para conduzir a análise proposta neste projeto

3.1 Aquisição

O dataset foi retirado do Kaggle:

https://www.kaggle.com/datasets/abdelrahmanemad594/laptop-prices/data

em formato CSV, e não requer autenticação especial para download. Os dados foram coletados originalmente via web scraping em sites de e-commerce durante 2024.

Por ter sido coletado de múltiplas fontes varejistas, o dataset tem campos de texto com variações de nomenclatura — como nomes de processadores e GPUs — o que torna necessário um passo de pré-processamento antes de qualquer modelagem.

3.2 Descrição origem

O dataset foi publicado pelo usuário Abdelrahman Emad na plataforma Kaggle. Os dados foram coletados de varejistas globais de tecnologia em 2024, sem amostragem intencional — representa o catálogo disponível no período de captura.

Os preços estão em Euros e a base é distribuída para fins educacionais e de pesquisa.

3.3 Descrição dataset

O dataset tem cerca de 1.150 registros e 18 colunas. As principais variáveis são:

Variavel	Descrição	Tipo
Company	A marca ou fabricante do laptop (ex.: HP, Acer, Asus).	String
Product	O nome ou identificador do modelo do laptop.	String
Type Name	O tipo de laptop (ex.: Notebook, Ultrabook).	String
Inches	O tamanho da tela do laptop em polegadas.	float
Screen Resolution	A resolução da tela do laptop	String
Ram	A quantidade de memória RAM no laptop, geralmente medida em GB	String
Opsys	O sistema operacional instalado no laptop	String
Cpu Brand	A marca da CPU (processador) usada no laptop	String
Cpu Model	O modelo específico da CPU	string
Cpu Rate	A velocidade do clock da CPU, geralmente medida em GHz	String

Ssd	O tamanho do armazenamento em Solid-State Drive (SSD) em GB	Int
Hdd	O tamanho do armazenamento em Hard Disk Drive (HDD) em GB	Int
Flash Storage	A quantidade de armazenamento flash adicional em GB	Int
Hybrid	Indica se o laptop possui uma configuração de armazenamento híbrido	Int
Gpu Brand	A marca da Unidade de Processamento Gráfico (GPU)	String
Gpu Model	O modelo específico da GPU	String
Price_Euros	O preço do laptop em euros (€)	int

4. Proposta analítica

O projeto está dividido em quatro frentes, cada uma ligada a uma disciplina do semestre:

a) Aquisição e Preparação dos Dados

Preparação dos Dados:

Ingestão do arquivo .csv e remoção da coluna vazia Unnamed: 16 Conversão da coluna Ram de string (ex.: "8GB") para numérico Conversão da coluna Cpu Rate de string (ex.: "2.5GHz") para numérico Tratamento de valores ausentes e normalização de strings

b) Análise Estatística Exploratória

Análise da distribuição das variáveis, identificação de outliers e estudo das relações entre as variáveis explicativas e o preço. Utilização de gráficos e medidas estatísticas para compreensão dos dados.

c) Análise Estatística Preditiva

Distribuição das variáveis e identificação de outliers em Price_euros Testes de hipótese (Kruskal-Wallis) para comparar preço médio entre marcas e tipos de laptop Regressão linear múltipla como baseline Matriz de correlação entre variáveis numéricas e o preçoFerramentas: Ferramentas: Python, Pandas, Scikit-learn, XGBoost e Matplotlib. Código versionado em Git.

d) Aprendizado de Máquina (Regressão)

Pergunta-chave: As features textuais extraídas via NLP melhoram a predição de preço?

Métricas de avaliação: RMSE, MAE e R^2 — com validação cruzada de 5 folds

4.1 Github Repository

Acesso ao repositório: https://github.com/oR1an/laptop-prize-analysis

5. Metodologia Analítica

Inicialmente, os dados passam por etapas de limpeza, padronização e transformação de variáveis.

Em seguida, é realizada análise exploratória (EDA), com o objetivo de compreender a distribuição dos dados, identificar padrões e possíveis outliers.

Para a modelagem, são utilizados algoritmos de regressão, como Regressão Linear e Random Forest, com o objetivo de prever o preço dos laptops com base em suas características técnicas.

6. Métricas de Avaliação

Para avaliar o desempenho dos modelos preditivos, serão utilizadas as seguintes métricas:

- RMSE (Root Mean Squared Error)
- MAE (Mean Absolute Error)
- R^2 (Coeficiente de Determinação)

Será utilizada validação cruzada com 5 folds para garantir robustez.

7. Data Storytelling

A análise dos dados busca compreender como diferentes características técnicas influenciam o preço dos laptops no mercado.

De forma geral, espera-se identificar que componentes como quantidade de memória RAM, tipo de armazenamento (SSD vs HDD), modelo de CPU e presença de GPU dedicada possuem impacto direto na formação do preço.

Além disso, a utilização de técnicas de análise busca compreender como diferentes características técnicas influenciam o preço dos laptops, permitindo identificar quais atributos agregam mais valor ao produto. permite extrair informações relevantes de variáveis textuais, como modelo de processador e placa de vídeo, enriquecendo a base de dados e melhorando a capacidade preditiva dos modelos.

Com isso, o projeto não apenas busca prever preços, mas também gerar insights estratégicos, permitindo entender quais atributos agregam mais valor ao produto e como esses fatores se relacionam no contexto do mercado de tecnologia.

8. Glossário

CSV: formato de arquivo de texto com valores separados por vírgulas.

Dataset: conjunto de dados estruturado em linhas e colunas.

EDA (Exploratory Data Analysis): análise exploratória de dados — técnicas para entender a distribuição e características dos dados antes da modelagem.

Feature Engineering: criação de novas variáveis a partir dos dados brutos para melhorar modelos de ML.

GPU (Graphics Processing Unit): processadora gráfica, pode ser integrada à CPU ou dedicada (com memória própria).

Outlier: valor que foge muito do padrão dos demais dados.

R^2 (Coeficiente de Determinação): métrica de avaliação de modelos de regressão. Quanto mais próximo de 1, melhor.

Random Forest: modelo de ML baseado em múltiplas árvores de decisão independentes.

RMSE (Root Mean Square Error): métrica de erro de predição. Quanto menor, melhor.

Variável-alvo: o que o modelo tenta prever. Aqui: Price_Euros (preço em euros).

9. Referências

KAGGLE. Laptop Prices Dataset. Disponível em: https://www.kaggle.com/datasets/abdelrahmanemad594/laptop-prices/data

SCIKIT-LEARN DEVELOPERS. scikit-learn: Machine Learning in Python. 2024. Disponível em: https://scikit-learn.org.